



# Analisi spettrale multivariata



Spesso interessa quantificare la relazione mutua tra due segnali, che possono essere sia di natura diversa, es: variabilità del battito cardiaco e pressione sanguigna, che della stessa natura, es. EEG prelevato da diverse posizioni dello scalpo.

Con riferimento al secondo esempio, l'analisi di coerenza permette di capire se due aree della corteccia cerebrale sono funzionalmente correlate, ad es. se hanno generatori sottocorticali comuni. E' stata impiegata fin dagli anni 60 in molteplici studi, tra cui

- fasi del sonno
- disordini psichiatrici
- effetto di farmaci
- patologie (emicrania, ischemia cerebrale ecc)
- in assenza di gravità (missione Gemini GT-7)
- meditazione trascendentale
- processi cognitivi



Se interpretiamo i due segnali come realizzazioni di due processi aleatori  $X$  e  $Y$  a tempo discreto, stazionari e a media nulla, la relazione mutua tra i due processi può essere quantificate sia nel dominio del tempo che della frequenza usando varie funzioni

- Cross-correlazione

$$R_{xy}(k) = E[x(n) y(n+k)]$$

- Cross spettro

$$P_{xy}(\omega) = \text{FT}[R_{xy}(k)]$$

- Coerenza

$$C_{xy}^2(\omega) = \frac{|P_{xy}(\omega)|^2}{P_x(\omega) \cdot P_y(\omega)}$$

# Cross correlazione: proprietà

La cross correlazione non è in generale una funzione pari, ma dall'ipotesi di stazionarietà segue

$$R_{xy}(k) = E[x(n)y(n+k)] = E[x(n-k)y(n)] = E[y(n)x(n-k)] = R_{yx}(-k)$$

1. Processi indipendenti (e a media nulla)


$$R_{xy}(k) = 0$$

2. Processi coincidenti  $X=Y$

$$R_{xy}(k) = R_x(k) = R_y(k)$$

3. Processi legati da una relazione lineare

$$R_{xy}(k) = h(k) \otimes R_x(k)$$




$$\begin{aligned} R_{xy}(k) &= E \left[ x(n) \sum_j h(j)x(n+k-j) \right] = \text{Dim:} \\ &= \sum_j h(j) E[x(n)x(n+k-j)] = \sum_j h(j) R_x(k-j) = \\ &= h(k) \otimes R_x(k) \end{aligned}$$

# Cross correlazione: proprietà

4. Processo  $Y$  è la somma di due componenti, la prima ( $Z$ ) legata da una relazione lineare al processo  $X$ , l'altra ( $E$ ) indipendente da  $X$

$$R_{xy}(k) = h(k) \otimes R_x(k)$$



$$y(n) = z(n) + e(n) = \sum_{k=-\infty}^n h(k)x(n-k) + e(n) = h(n) \otimes x(n) + e(n)$$

Dim:


$$\begin{aligned} R_{xy}(k) &= E[x(n)(z(n+k) + e(n+k))] = E[x(n)z(n+k)] + E[x(n)e(n+k)] = \\ &= R_{xz}(k) = h(k) \otimes R_x(k) \end{aligned}$$

*La cross correlazione isola il legame tra  $X$  e  $Z$ , cioè tra  $X$  e la componente di  $Y$  linearmente legata a  $X$*



# Cross spettro

E' la FT della funzione di cross correlazione. Evidenzia le componenti spettrali comuni ai due processi. Per esemplificare, se consideriamo due segnali deterministici che hanno in comune una componente a 30 Hz


$$x(t) = A_1 \sin(2\pi 10t) + A_2 \sin(2\pi 30t)$$



$$y(t) = A_1 \sin(2\pi 30t) + A_2 \sin(2\pi 50t)$$



Il cross spettro evidenzia la componente a 30 Hz



# Cross spettro: proprietà

E' in generale una funzione complessa, dato che la cross correlazione non è in generale pari

1. Processi indipendenti (e a media nulla)

$$P_{xy}(\omega)=0$$

2. Processi coincidenti  $X=Y$

$$P_{xy}(\omega)=P_x(\omega)=P_y(\omega)$$

3. Processi legati da una relazione lineare

$$P_{xy}(\omega) = H(\omega)P_x(\omega)$$

4. Processo  $Y$  somma di due componenti, la prima ( $Z$ ) legata da una relazione lineare al processo  $X$ , l'altra ( $E$ ) indipendente da  $X$

$$P_{xy}(\omega) = P_{xz}(\omega) = H(\omega)P_x(\omega)$$

*Il cross spettro coincide con lo spettro della componente di  $Y$  linearmente legata a  $X$ .*

# Funzione coerenza

$$C_{xy}^2(\omega) = \frac{|P_{xy}(\omega)|^2}{P_x(\omega) \cdot P_y(\omega)} = C_{yx}^2(\omega)$$

E' una funzione reale, che normalizza il modulo al quadrato dello spettro incrociato tra due processi rispetto agli spettri dei due processi

1. Processi indipendenti (e a media nulla)

$$C_{xy}^2(\omega) = 0$$

2. Processi coincidenti  $X=Y$

$$C_{xy}^2(\omega) = 1$$

3. Processi legati da una relazione lineare

$$C_{xy}^2(\omega) = 1$$

$$\text{Dim: } C_{xy}^2(\omega) = \frac{|P_{xy}(\omega)|^2}{P_x(\omega) \cdot P_y(\omega)} = \frac{|H(\omega)P_x(\omega)|^2}{P_x(\omega) \cdot |H(\omega)|^2 P_x(\omega)} = 1$$

**La funzione coerenza è una funzione reale di  $\omega$ , compresa tra zero (processi indipendenti) e 1 (processi linearmente legati)**



# Funzione coerenza

4. Processo Y somma di due componenti, la prima (Z) legata da una relazione lineare al processo X, l'altra (E) indipendente da X

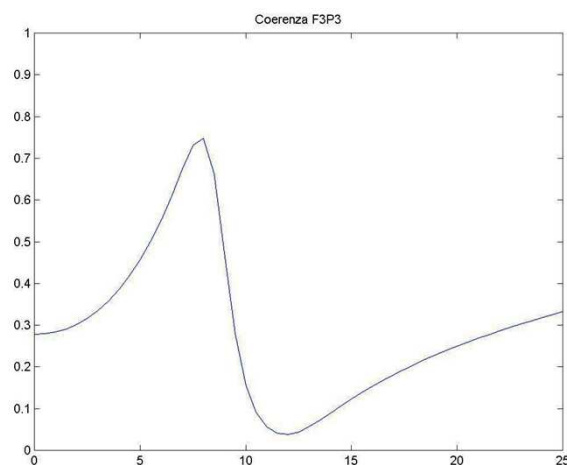
$$C_{xy}^2(\omega) = \frac{|H(\omega)P_x(\omega)|^2}{P_x(\omega)P_y(\omega)} = \frac{P_z(\omega)}{P_y(\omega)}$$

Pertanto, essendo:  $P_y(\omega) = P_z(\omega) + P_E(\omega)$

$$C_{xy}^2(\omega)P_y(\omega) = P_z(\omega)$$

$$[1 - C_{xy}^2(\omega)]P_y(\omega) = P_E(\omega)$$

La funzione coerenza consente di separare il processo Y nelle due componenti, per ogni valore di pulsazione!!



Esempio: funzione coerenza tra EEG misurati da elettrodi diversi, nel range 0-20 hz

I due segnali hanno un valore di coerenza prossimo ad uno ad una frequenza attorno ai 9 hz (ritmo alfa) quindi se adottiamo la relazione lineare+rumore, possiamo concludere che i due processi sono legati in modo pressochè lineare in banda alfa (prevale la componente z) ma non nelle altre bande, dove prevale la componente scorrelata

# Funzione coerenza: come si stima?

Per calcolare gli spettri  $P_x$ ,  $P_y$ ,  $P_{xy}$ :

- Metodi tradizionali  
(basati sulla Trasformata di Fourier)
- Metodi parametrici  
(basati sull'impiego di modelli multivariati)

# Metodi FT

La stima della funzione coerenza con i metodi FT richiede alcune cautele. Infatti, se ad es. sotto ipotesi di ergodicità, si stimano gli spettri  $P_x$ ,  $P_y$ , con il metodo del periodogramma e si estendono principi analoghi (definizione di uno stimatore della cross correlazione, e poi sua FT) per il calcolo di  $P_{xy}$  si ottiene un risultato non informativo

$$\hat{R}_{xy}(k) = \frac{1}{N} \sum_{n=0}^{N-1-k} x(n)y(n+k) = \frac{1}{N} x(k) \otimes y(-k)$$

$$\hat{P}_{xy}(\omega) = \frac{1}{N} X(\omega)Y(-\omega)$$

$$\hat{P}_x(\omega) = \frac{1}{N} |X(\omega)|^2$$


$$\hat{P}_y(\omega) = \frac{1}{N} |Y(\omega)|^2$$

*Quindi per avere dei risultati informativi è indispensabile applicare ai metodi di stima degli spettri la tecnica di averaging per migliorare le proprietà degli stimatori!!!*







$$C_{xy}^2(\omega) = 1$$

# Esempio



60 sec EEG divisi in 30 epoche di 2 sec  
 $F_c = 256$  Hz,  $N = 512$



Frequency(Hz)

Frequency(Hz)

Gli spettri sono stati calcolando per ogni epoca e poi sono stati mediati (stazionarietà??)

La DFT fornisce 512 campioni equispaziati in un intervallo pari alla frequenza di campionamento, quindi la risoluzione spettrale è di 0.5 Hz

Rimangono comunque i problemi di leakage...

# Metodi parametrici

I due processi X e Y vengono descritti come le uscite di un modello AR multivariato, pilotato da due processi bianchi, a media nulla. Se ora indichiamo i due processi con  $y_1$  e  $y_2$ , il modello stabilisce un legame tra  $y_1$  all'istante  $n$  e non solo  $y_1$  in  $p$  istanti precedenti e il rumore  $u_1$  all'istante attuale, ma anche  $y_2$  nei  $p$  istanti precedenti. Analogamente per  $y_2$



$$y_1(n) = -\sum_{k=1}^P a_k^{(1,1)} y_1(n-k) - \sum_{k=1}^P a_k^{(1,2)} y_2(n-k) + u_1(n)$$

$$y_2(n) = -\sum_{k=1}^P a_k^{(2,1)} y_1(n-k) - \sum_{k=1}^P a_k^{(2,2)} y_2(n-k) + u_2(n)$$

# Modello AR multivariato

$$y_1(n) = -\sum_{k=1}^P a_k^{(1,1)} y_1(n-k) - \sum_{k=1}^P a_k^{(1,2)} y_2(n-k) + u_1(n)$$

$$y_2(n) = -\sum_{k=1}^P a_k^{(2,1)} y_1(n-k) - \sum_{k=1}^P a_k^{(2,2)} y_2(n-k) + u_2(n)$$

In forma matriciale :

$$\underline{y}(n) = \sum_{k=1}^p \underline{A}_k \cdot \underline{y}(n-k) + \underline{u}(n)$$

$\underline{y}(n)$  è il vettore  $[2 \times 1]$  di processi aleatori

$\underline{A}_k$  matrice  $[2 \times 2]$  dei coefficienti, es

$$\underline{A}_1 = \begin{bmatrix} a_1^{(1,1)} & a_1^{(1,2)} \\ a_1^{(2,1)} & a_1^{(2,2)} \end{bmatrix}$$

$\underline{u}(n)$  è il vettore  $[2 \times 1]$  di rumore bianco a media nulla e matrice di varianza:

$$\Sigma_u = \begin{bmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{bmatrix}$$

Per identificare i parametri si possono scrivere equazioni analoghe a quelle di Yule Walker, in funzione di  $\underline{R}(k) = E[\underline{y}(n)\underline{y}(n+k)]$  matrice di autocorrelazione  $[2 \times 2]$ , che ha sulla diagonale principale le correlazioni dei due processi e fuori della diagonale le cross-correlazioni

# Matrice di densità spettrale

Una volta identificato il modello, è possibile stimare la matrice [2x2] delle densità spettrali

$$\underline{P}_y(\omega) = \begin{bmatrix} P_1(\omega) & P_{12}(\omega) \\ P_{21}(\omega) & P_2(\omega) \end{bmatrix}$$

usando la seguente relazione che lega la matrice della densità spettrale del vettore di processi in uscita  $P_y$  alla matrice di trasferimento  $H$  (valutata per  $z=e^{j\omega}$ ) e alla matrice della densità spettrale del vettore di rumore bianco in ingresso  $\Sigma_u$


$$P_y(\omega) = \underline{H}(\omega) \cdot \Sigma_u \cdot \underline{H}^T(\omega) \quad \text{con} \quad \underline{H}(\omega) = \left( I - \sum_{k=1}^p A_k z^{-k} \right)^{-1}_{z=e^{j\omega}}$$

La matrice  $P_y$  è Hermitiana, gli elementi sulla diagonale sono reali e rappresentano gli auto spettri, mentre quelli fuori diagonale sono complessi e rappresentano i cross-spettri.

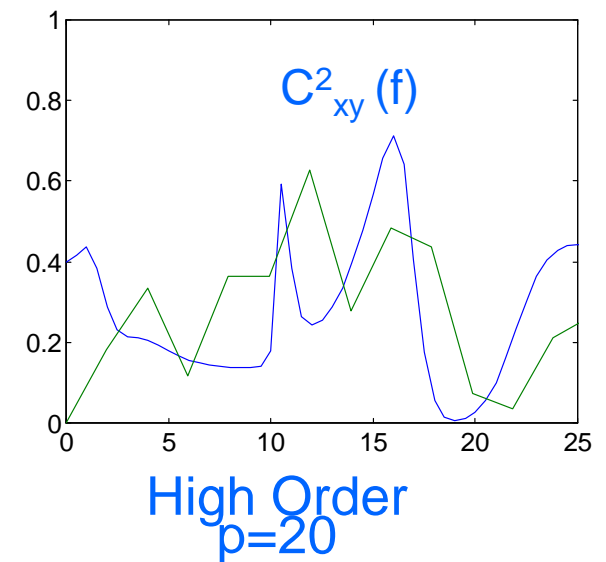
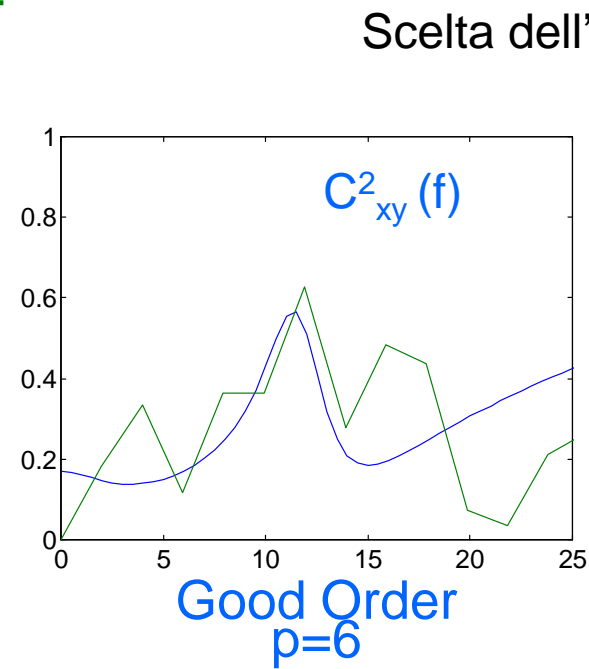

Coerenza

$$C_{12}^2(\omega) = \frac{|P_{12}(\omega)|^2}{P_1(\omega) \cdot P_2(\omega)} = C_{21}^2(\omega)$$




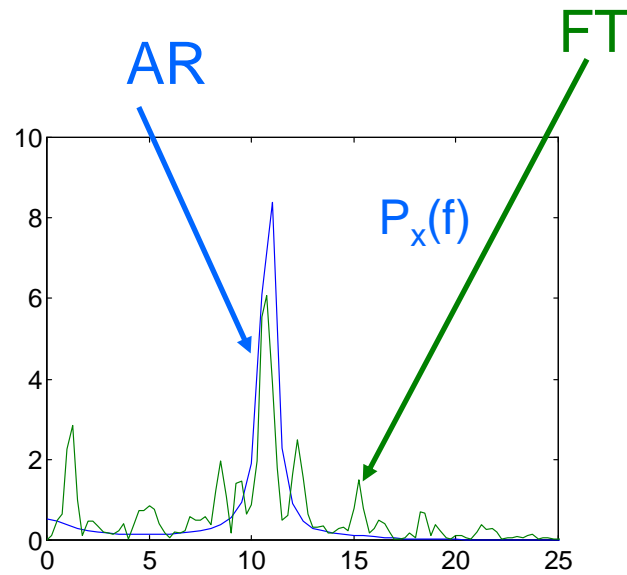
# Esempio



2 sec EEG  
 $F_c=256$  Hz,  $N=512$







## Parametri

$$A_1 = \begin{bmatrix} 1.60 & -0.40 \\ 0.09 & 1.30 \end{bmatrix}$$

$$A_2 = \begin{bmatrix} -0.55 & 0.71 \\ -0.14 & 0.39 \end{bmatrix}$$

$$A_3 = \begin{bmatrix} -0.01 & -0.20 \\ 0.36 & -0.67 \end{bmatrix}$$

$$A_4 = \begin{bmatrix} -0.29 & -0.02 \\ -0.25 & -0.04 \end{bmatrix}$$

$$A_5 = \begin{bmatrix} 0.28 & -0.29 \\ 0.30 & -0.37 \end{bmatrix}$$

$$A_6 = \begin{bmatrix} -0.15 & 0.18 \\ -0.22 & 0.34 \end{bmatrix}$$


$$\Sigma = \text{diag}[1.30, 1.20]$$

# Indici di coerenza

In modo del tutto analogo a quanto visto per lo spettro del segnale EEG, anche a partire dalla funzione coerenza si possono definire degli indici quantitativi, ad es.

- Frequenza media (C\_MDF)

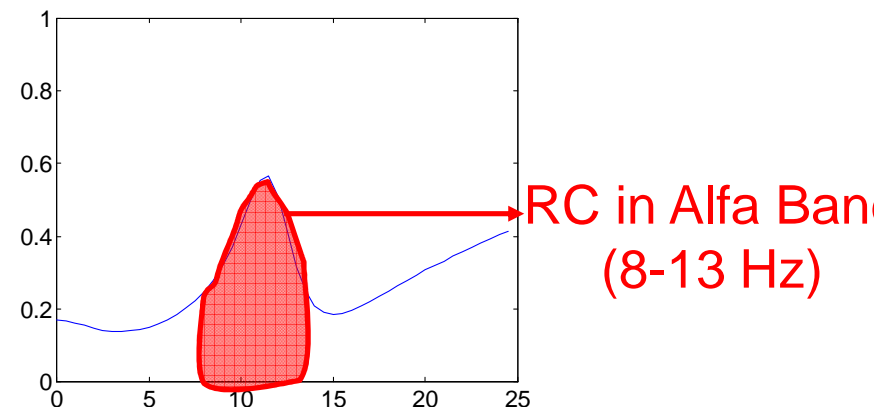
$$C\_MDF = \frac{\int_{0.5}^{f_{\max}} f \cdot C_{xy}^2(f) df}{\int_{0.5}^{f_{\max}} C_{xy}^2(f) df}$$



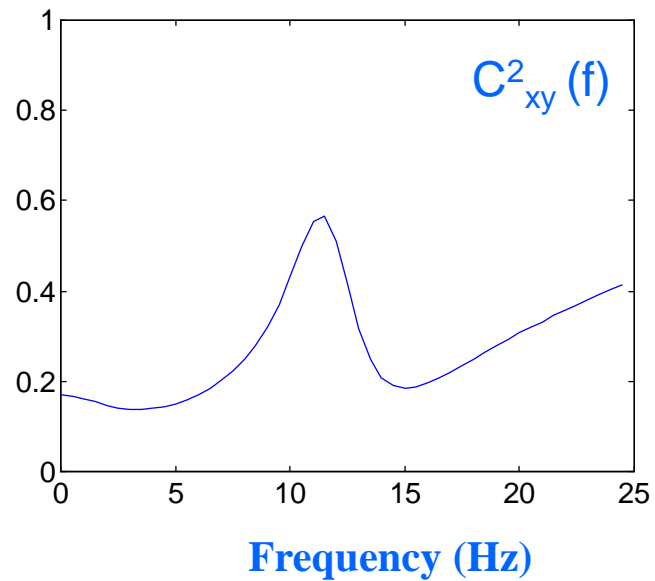

- Frequenza del massimo  $F_{\max}$

- Coerenza relativa nelle varie bande

$$RC = 100 \cdot \frac{\int_{\text{low}}^{\text{high}} C_{xy}^2(f) df}{\int_{0.5}^{f_{\max}} C_{xy}^2(f) df}$$



# Esempio



## Coherence Indices

C_MDF	fCmax	Deta RC	Theta RC	Alfa RC	Beta RC
14.46	11.50	8.33	9.86	19.36	57.16

high=4 Hz, low =0.5 Hz for  $\delta$  band  
 high=8 Hz, low =4 Hz for  $\theta$  band  
 high=13 Hz, low =8 Hz for  $\alpha$  band  
 high=25 Hz, low =13 Hz for  $\beta$  band

# Riassumendo:

La funzione coerenza, compresa tra zero e uno, misura il grado di legame (lineare) tra due segnali, in funzione della frequenza.

E' una misura di sincronismo tra due segnali, cioè permette di individuare le frequenze in cui i due processi risultano avere un certo grado di associazione, ma non permette di introdurre alcuna misura di causalità, cioè di capire quale dei due segnali pilota l'altro. Questo rappresenta un limite della coerenza.

Per ovviare a ciò, esistono :

- definizioni alternative della funzione coerenza, ad esempio la coerenza diretta (DTF)

$$DTF_{1 \rightarrow 2}(\omega) = \frac{\sigma_1 H_{21}(\omega)}{\sqrt{\sigma_2^2 |H_{22}(\omega)|^2 + \sigma_1^2 |H_{21}(\omega)|^2}}$$

$$DTF_{2 \rightarrow 1}(\omega) = \frac{\sigma_2 H_{12}(\omega)}{\sqrt{\sigma_1^2 |H_{11}(\omega)|^2 + \sigma_2^2 |H_{12}(\omega)|^2}}$$

A differenza dalla coerenza ordinaria, la DTF fornisce indicazioni sulla direzione dell'interazione tra due segnali

- Indici di causalità di Granger

# Causalità secondo Granger

La definizione è stata formulata nel 1969 da Granger (premio Nobel per l'economia nel 2003),

Dati due segnali  $x$  e  $y$ , si può dire che  $x$  influenza  $y$  se:

- l'informazione di  $x$  è utile a predire  $y$  (1° criterio)
- includendo i valori passati di  $x$  nella stima regressiva di  $y$ , si migliora la qualità della stima, ovvero si riduce l'errore di predizione (2° criterio)



# Causalità di Granger -1° criterio

Il modello AR multivariato viene utilizzato non solo come passo intermedio per il calcolo dello spettro incrociato e quindi della funzione coerenza, ma anche per capire se, in presenza di una coerenza non trascurabile, è il primo segnale che pilota il secondo, oppure il secondo che pilota il primo, oppure ci sono controlli incrociati tra i due segnali. A tal fine vengono osservati i valori degli elementi fuori della diagonale principale delle matrici  $\underline{A}_k$

$$\underline{A}_k = \begin{vmatrix} a_k^{(1,1)} & a_k^{(1,2)} \\ a_k^{(2,1)} & a_k^{(2,2)} \end{vmatrix}$$

Si possono avere 4 situazioni:

$y_1$  causa  $y_2$  ma non viceversa se almeno un elemento in posizione (2,1) è significativamente diverso da zero mentre tutti gli elementi (1,2) non lo sono

$y_2$  causa  $y_1$  ma non viceversa se almeno un elemento in posizione (1,2) è significativamente diverso da zero mentre tutti gli elementi (2,1) non lo sono

$y_1$  causa  $y_2$  e  $y_2$  causa  $y_1$  se almeno un elemento in posizione (1,2) e almeno un elemento in posizione (2,1) sono significativamente diversi da zero

$y_1$  e  $y_2$  sono scorrelati tra loro se tutti i coefficienti in posizione (1,2) e (2,1) non sono significativamente diversi da zero

# Causalità di Granger - 2° criterio

L'indice di causalità viene definito come

$$GC_{x \rightarrow y} = \ln \frac{\text{var}(y)}{\text{var}(y|x)}$$

dove

- $\ln$  è il logaritmo naturale
  - $\text{var}(y)$  è la varianza del rumore di ingresso per il modello AR monovariato, che misura la possibilità di predire  $y$  sulla base della sua storia passata
  - $\text{var}(y/x)$  è la varianza del rumore di ingresso per il modello multivariato, che misura la possibilità di predire a partire dalla storia passata non solo di  $y$  ma anche di  $x$ .
- a) GC è sempre definito non negativo
- b)  $GC = 0$  quando nessun legame causale esiste tra i segnali :  $\text{var}(y) = \text{var}(y/x)$
- c) GC significativamente diverso da zero indica la presenza di una relazione di casualità da  $x$  a  $y$
- d) Il valore di GC è una misura della forza del legame
- e) Una differenza significativa tra gli indici di causalità  $x \rightarrow y$  e  $y \rightarrow x$  indica il verso della relazione

# Come valutare la significatività?

## Test statistico (F-test)

Ipotesi nulla  $H_0 : \text{var}(y) = \text{var}(y|x)$

Statistica F

$$F = \frac{\frac{\text{var}(y) - \text{var}(y | x)}{p}}{\frac{\text{var}(y | x)}{(L - 2p - 1)}}$$

P = dimensione del modello MVAR


L= numero di campioni

Sotto  $H_0$  F è distribuita secondo la statistica [F di Fisher-Snedecor](#) con df pari a p e L-2p-1

Fissato un intervallo di significatività (es. Alfa=0,05) si valuta se accettare o rifiutare l'ipotesi nulla



# Applicazione: Analisi di coerenza dell'EEG per lo studio della connettività cerebrale






# Why connectivity?

*«One of the most important goals of neuroscience is to establish precise structure-function relationships in the brain.»*


Stephan KE (2004). On the role of general system theory for functional neuroimaging. J.Anat. 205, 443-470.



**Connectivity  
variability**



**PLASTICITY**






Development  
Learning  
Perception  
Adaptive response to injury



# Connectivity

## STRUCTURAL, FUNCTIONAL & EFFECTIVE



**structural connectivity**  
presence of axonal connections



by using MRI and DTI  
(fiber tracking)

**functional connectivity**  
statistical dependencies between  
regional time series



by using  
fMRI and  
EEG/MEG



**effective connectivity**  
causal (directed) influences between  
neurons or neuronal populations



# How to evaluate connectivity?

TOPOLOGY

STRENGTH

CAUSALITY  
DIRECTED/INDIRECTED

Two approaches

Model based

- A priori knowledge on
  - topology
  - causality
- Inference of
  - strength

Data driven

- Inference of
  - topology
  - causality
  - strength

**SEM (Structural Equation Modeling)**

implemented in commercial (Lisrel) and free (R) packages

**MVAR (Multi-Variate Autoregressive Models)**


implemented in MATLAB tools





# SEM

## Assumptions


1. Known network topology



Example



2. Linear structural equation



Example:

$$\begin{aligned} EEG_2(n) &= \alpha EEG_1(n) + e_2(n) \\ EEG_3(n) &= \beta EEG_1(n) + \gamma EEG_2(n) + e_3(n) \end{aligned}$$

## Estimate

$\alpha$   $\beta$   $\gamma$  are estimated by maximum likelihood, based on the comparison between:


- sample covariance (estimated from the data)
- model covariance (expressed in terms of  $\alpha$   $\beta$   $\gamma$ )



# MVAR

## Assumptions

## MVAR Model



## Example:

$$EEG_1(n) = \sum_{k=1}^P a_k^{(1,1)} EEG_1(n-k) + \sum_{k=1}^P a_k^{(1,2)} EEG_2(n-k) + \sum_{k=1}^P a_k^{(1,3)} EEG_3(n-k) + e_1(n)$$

## Estimate

- $a_{ij}$  coefficients are estimated by using weighted least squares methods
- model order  $P$  is selected based on validation criteria

## From MVAR


- Granger indices
- Coherence and other frequency indices (DTF)

**How well do SEM and  
MVAR reveal brain  
functional connections?**



# Simulation study

1. EEG signals are generated based on known connectivities.

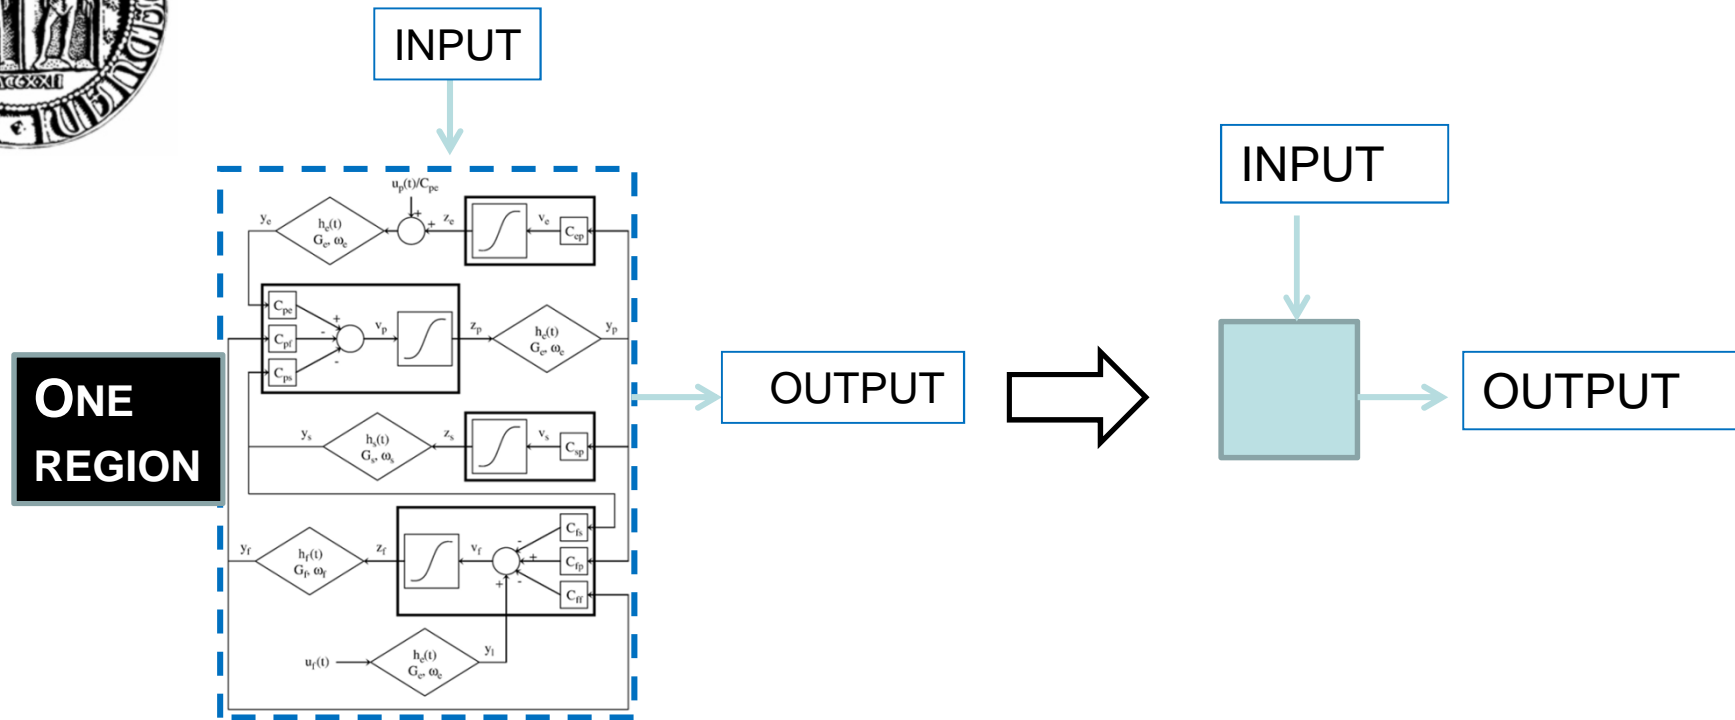


2. On these data, SEM parameters and MVAR indexes were estimated.
3. Comparison between the true and the estimated networks.





# 1. Neural mass model (Ursino et al, 2006)




# NETWORK

## Known connecting weights A, B, C

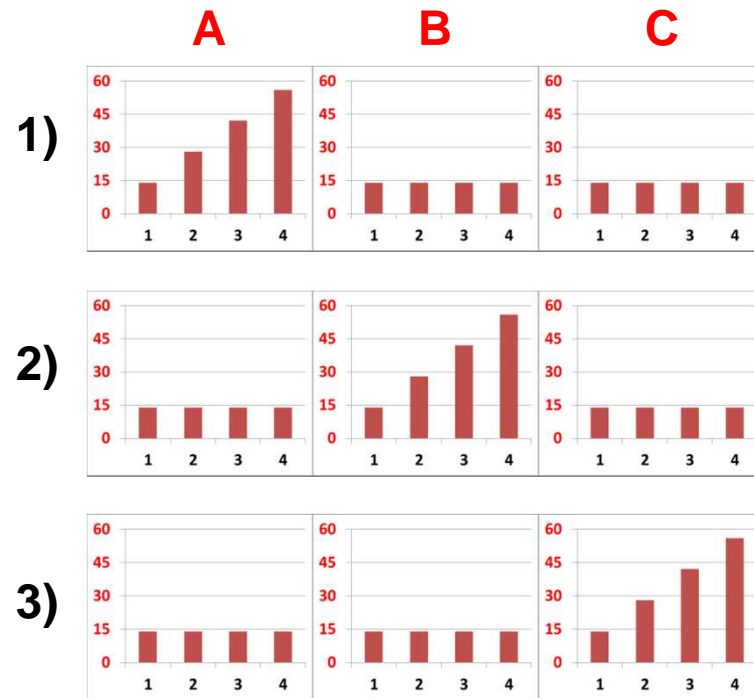

e.g. for ROI 2:

White noise is the endogenous input  
 EEG in ROI1 is the exogenous input  
 EEG in ROI2 is the output





## 2. Implementation

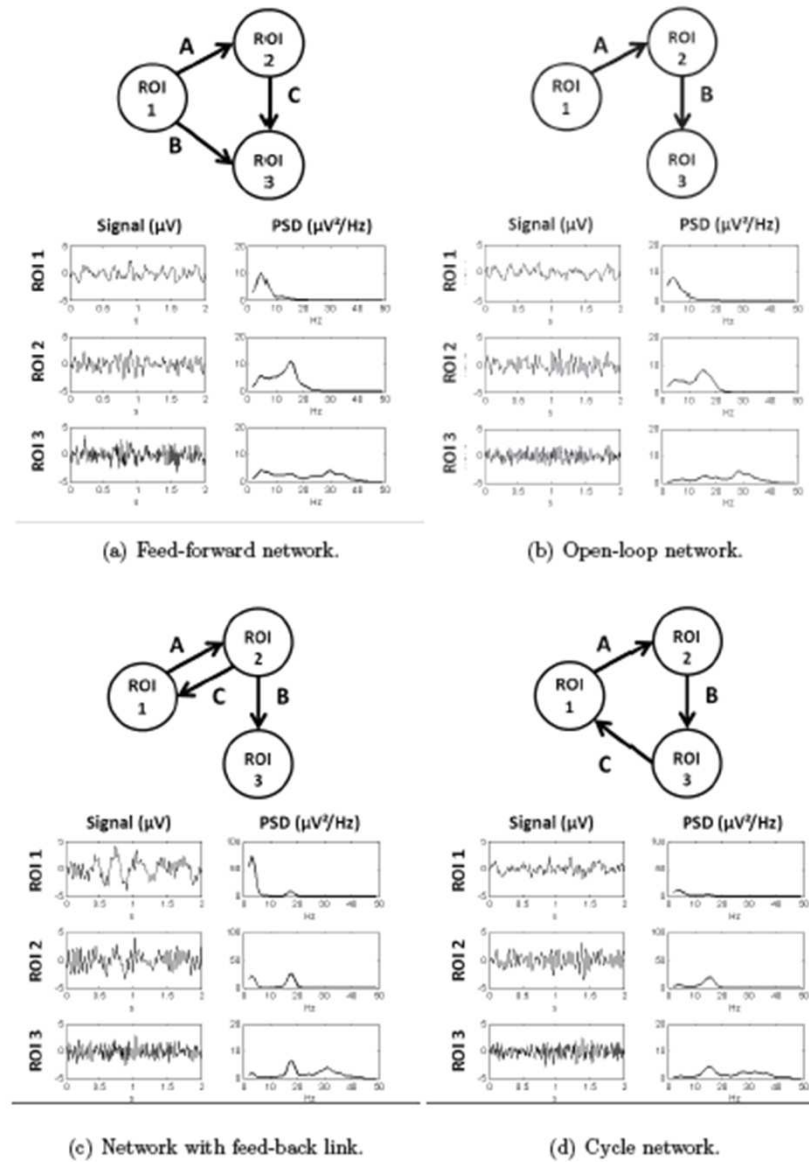


Different networks  
are simulated,  
characterized by:  
different topologies  
different values of  
A, B, C

For each model:  
100 realizations are  
generated



# 3. Examples of EEG data




## 5. MVAR – GC and Frequency indexes

On each data set (triplet of EEGs from the three ROIs) a MVAR model is estimated


From MVAR:

GC is evaluated. It provides information on: 1. topology (significant GC means that a connection is present) 2. strength (CG value) 3. direction

Coherence is evaluated, and by elaborating on it, DTF and PDC are defined to measure the **LINEAR** coupling  $A \rightarrow B$  at various frequencies.



**No significant  
coupling**

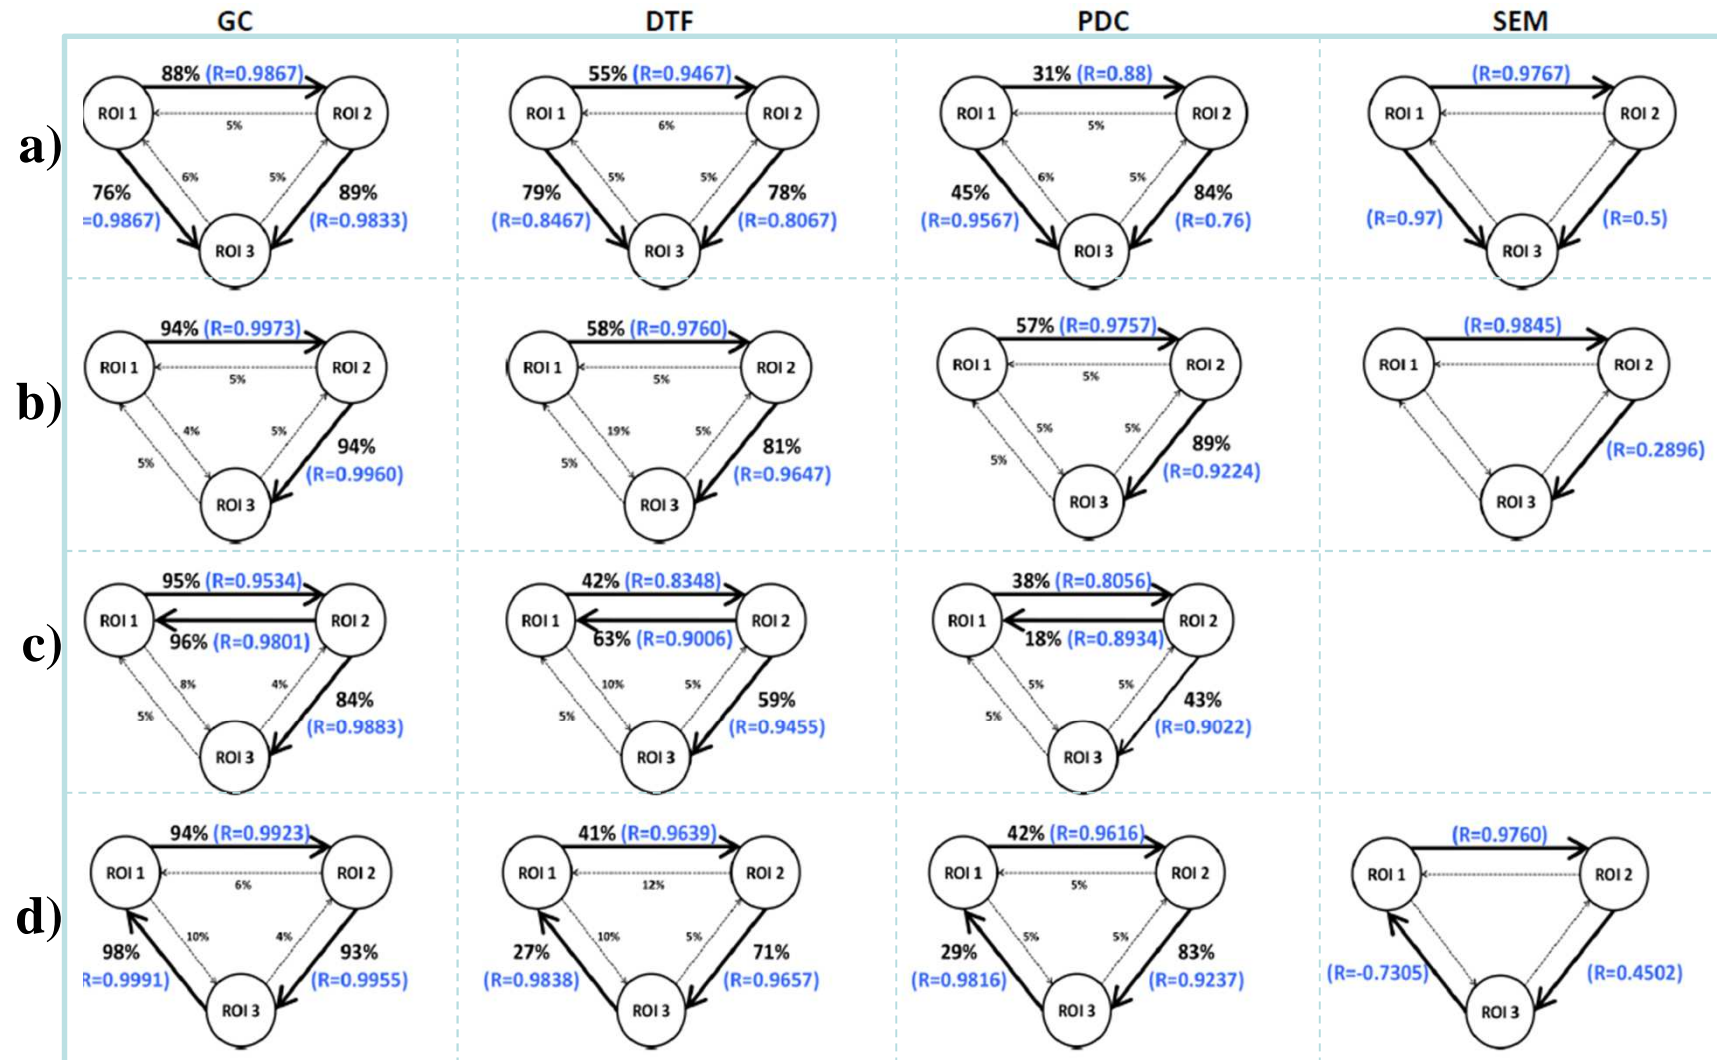


**Significant  
coupling at ~15 Hz**

90%  
interval  
under null  
hypothesis

# 4. Results

Inferred topologies by Granger causality index (GC), frequency indices (DTF and PDC) and Structural Equation Modeling (SEM). Continuous lines indicate true connections and the associated numbers quantify the percentage of true positives, averaged across datasets. Dashed lines indicate absent connections, and the associated numbers quantify the percentage of false positives averaged across dataset. The blue numbers associated with continuous lines indicate the correlation coefficient between true (i.e. assumed in the model) and estimated values.





# Conclusion

TOPOLOGY

STRENGTH


DIRECTED/INDIRECTED  
CAUSALITY

SEM


known



known

Granger Causality 



Frequency indices 



*Granger causality and  
frequency indexes are  
not competitive but  
complementary  
techniques*



**Use  
together!**